МИНОБРНАУКИ РОССИИ
САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ
ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)

Кафедра ИС

ОТЧЕТ

по практической работе №1

по дисциплине: “Безопасность искусственного интеллекта”

Бригада 5, гр. 1378 — Виноградов А.С., Угрюмов М.М., Таланков В.Р.

Руководитель — Новикова Е.С.

Санкт-Петербург
2026

СОДЕРЖАНИЕ

1. Цель работы.....3

2. Постановка задачи и фиксация параметров эксперимента.....3

2.1. Аналитическая задача и контекст применения.....3

2.2. Описание набора данных.....3

2.3. Входная и выходная модальности.....4

2.4. Формирование обучающей, валидационной и тестовой выборок.....4

2.5. Архитектура глубокой модели и обучение baseline.....4

2.6. Основная метрика качества.....5

2.7. Фиксация параметров эксперимента.....5

3. Подход к оценке качества данных.....6

3.1. Проверяемые свойства данных.....6

3.2. Доверительные интервалы.....6

4. Результаты.....7

4.1. Полнота и валидность.....7

4.2. Уникальность и дедупликация.....8

4.3. Train-test leakage.....8

4.4. Качество разметки.....8

4.5. Баланс классов.....8

4.6. Репрезентативность (train vs test).....8

4.7. Аномалии.....9

ЗАКЛЮЧЕНИЕ.....9

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ.....10

1. Цель работы

Получить количественный профиль качества набора данных и определить свойства данных, которые потенциально могут повлиять на надежность, робастность и приватность обученной модели. Качество данных рассматривается как многомерное свойство.

2. Постановка задачи и фиксация параметров эксперимента

2.1. Аналитическая задача и контекст применения

Аналитическая задача: мультиклассовая классификация изображений листьев пшеницы по состоянию здоровья/заболеванию. Контекст применения: автоматическая диагностика заболеваний пшеницы по фотографиям листьев, например, в составе мобильного или веб-сервиса поддержки принятия решений агрономом, автоматический полив пестицидами.

2.2. Описание набора данных

Датасет:https://www.kaggle.com/datasets/kushagra3204/wheat-plant-diseases/data сокращен до 6 классов (убраны фотографии с паразитами растений (минус 4 класса).

Размер выборки: 6467 изображений. Разбиение: train = 4922, valid = 752, test = 793.

Тип аналитической задачи: мультиклассовая классификация.

Модальность данных: цветные изображения в формате RGB.

Размерность входа: переменное исходное разрешение; при обучении используется преобразование EfficientNet-B5 (размер 456×456 пикселей после нормализации ImageNet).

Число классов: 6. Классы: black_rust, brown_rust, healthy, mildew, septoria, smut.

Способ разбиения train/validation/test: 75/15/15 train, valid и test; разбиение зафиксировано в файле artifacts/dataset_manifest.csv.

2.3. Входная и выходная модальности

Входная модальность: тензор изображения RGB (3×H×W), нормализованный по статистикам ImageNet. Выходная модальность: дискретная метка класса (0..5), соответствующая одному из шести состояний растения.

2.4. Формирование обучающей, валидационной и тестовой выборок

Выборки сформированы на основе исходной структуры папок датасета. Для воспроизводимости создан CSV-манифест artifacts/dataset_manifest.csv, содержащий путь к каждому файлу, название сплита, имя класса и числовой индекс класса. Повторное разбиение не производилось. Распределение приведено в Таблице №1.

Таблица №1 – Распределение изображений по классам и выборкам

Класс	**Train**	**Valid**	**Test**
black_rust	504	60	82
brown_rust	856	60	90
healthy	766	150	154
mildew	846	157	148
septoria	896	161	157
smut	1054	164	162

2.5. Архитектура глубокой модели и обучение baseline

Архитектура: efficientnet_b5 с пред обученными весами EfficientNet_B5_Weights.IMAGENET1K_V1. Классификационная формула: Dropout(0.2) + Linear(2048 -> 6). Backbone заморожен: True. Число обучаемых параметров: 12 294.

Гиперпараметры обучения:

- оптимизатор Adam с learning rate = 0.001,
- функция потерь CrossEntropyLoss, ы
- число эпох 15,
- размер batch 16,

- seed 42.

Обучение проводилось с mixed precision (AMP) на NVIDIA GeForce RTX 4070 SUPER. Early stopping: patience = 6 по метрике valid_macro_f1.

Модель и параметры эксперимента сохранены в репозитории: веса – artifacts/models/baseline_effnetb5.pth, конфигурация – artifacts/train_config.json, история обучения – artifacts/train_history.json.

2.6. Основная метрика качества

Основная метрика задачи – Accuracy, как наиболее интерпретируемая для сбалансированной мультиклассовой классификации. На тестовой выборке Accuracy = 0.8449 [0.8180, 0.8684] (95% CI Уилсона). Дополнительная метрика – Macro-F1 = 0.8301 [0.8028, 0.8554] (bootstrap, B = 2000).

2.7. Фиксация параметров эксперимента

В Таблице №2 указано, где в репозитории зафиксирован каждый параметр, необходимый для воспроизводимости.

Таблица №2 – Соответствие параметров эксперимента и артефактов репозитория

Параметр	**Место в репозитории**
Версия и источник набора данных	https://www.kaggle.com/datasets/kushagra3204/wheat-plant-diseases/data с удалением классов с паразитами
Схема train/validation/test split	artifacts/dataset_manifest.csv
Случайный seed	artifacts/train_config.json: seed = 42
Архитектура и инициализация модели	artifacts/train_config.json + artifacts/models/baseline_effnetb5.pth
Гиперпараметры обучения	artifacts/train_config.json
Версии ключевых библиотек	artifacts/train_config.json: Python 3.13.11, torch 2.14.1+cu130, torchvision 0.29.1+cu130
Основная метрика и способ вычисления	artifacts/test_metrics.json: Accuracy (Wilson CI), Macro-F1 (bootstrap B=2000)

3. Подход к оценке качества данных

3.1. Проверяемые свойства данных

В соответствии с методическими рекомендациями оценены свойства качества данных, отображенные в Таблице №3.

Таблица №3 – Оценка свойств качества данных

Свойство	**Метод**	**Инструмент**
Полнота / валидность	Чтение файлов, проверка битых изображений	OpenCV
Уникальность	Exact duplicates (MD5), near duplicates (pHash)	hashlib, imagehash
Train-test leakage	Perceptual hash train vs test	imagehash
Качество разметки	Confident Learning на out-of-sample probs (5-fold CV)	cleanlab
Баланс	Imbalance ratio, нормированная энтропия	NumPy
Репрезентативность	MMD (kernel two-sample test) и C2ST	scikit-learn, SciPy
Аномалии	Aspect ratio, Laplacian blur, яркость, контраст, BRISQUE	OpenCV, piq

3.2. Доверительные интервалы

Для долей (broken rate, duplicate rate, leakage rate, label error rate) использован 95%-ый интервал Уилсона. Для Macro-F1 baseline-модели использован bootstrap (B = 2000, percentile CI). Для MMD приведена permutation p-value; для C2ST – bootstrap CI по объектам.

4. Результаты

Результаты оценки качества данных представлены в сводной Таблице №4.

Таблица №4 – Сводные результаты оценки качества данных

Свойство	Метрика	Значение	95% CI	Интерпретация
Полнота / валидность	broken rate	0.0000	[0.0000, 0.0006]	0 битых файлов
Уникальность	exact duplicate rate	0.4531		2930 изображений
Уникальность	near duplicate rate	0.5997		3878 изображений
Train-test leakage	leakage rate	0.6204	[0.5861, 0.6535]	492 тестовых образцов
Качество меток	label error rate	0.0146	[0.0116, 0.0184]	cleanlab, 72 подозрительных меток
Баланс	imbalance ratio	2.09	–	0.988 норм. энтропии
Репрезентативность	MMD	0.005415	p = 0.0000	Дрейф обнаружен
Репрезентативность	C2ST accuracy	0.9500	[0.9687, 0.9862]	Классификатор отличает train от test
Аномалии	extreme aspect	–	–	754 изображений
Аномалии	low blur	–	–	490 изображений

4.1. Полнота и валидность

Проверено чтение всех 6467 изображений. Битых / нечитаемых файлов: 0 (broken rate = 0.0000).

Пропуски в метаданных и нарушения формата не обнаружены.

4.2. Уникальность и дедупликация

Exact duplicates (MD5): 2930 изображений (0.4531, 95% CI: [0.4410, 0.4652]). Near duplicates (pHash, threshold ≤ 10): 3878 изображений (0.5997, 95% CI: [0.5877, 0.6115]).

Высокая доля дубликатов свидетельствует о значительном дублировании объектов в датасете.

4.3. Train-test leakage

Метод: perceptual hash (pHash) для попарного сравнения train и test. Найдено 1504 пар с расстоянием ≤ 10. Утечка затрагивает 492 из 793 тестовых изображений (0.6204, 95% CI: [0.5861, 0.6535]).

Потенциально серьезное завышение оценки качества модели.

4.4. Качество разметки

Для оценки качества меток использован метод Confident Learning (cleanlab) на out-of-sample вероятностях, полученных 5-fold cross-validation. Число подозрительных меток: 72 из 4922 (0.0146, 95% CI: [0.0116, 0.0184]). Топ-объектов с низким качеством разметки сохранены в файл pr1_data_quality/results/pr1_suspicious_labels.csv.

4.5. Баланс классов

Imbalance ratio (max/min в train): 2.09. Нормированная энтропия распределения классов: 0.988 (1.0 – идеально сбалансированное распределение).

Набор данных близок к сбалансированному, однако небольшой дисбаланс присутствует.

4.6. Репрезентативность (train vs test)

Для сравнения распределений train и test использованы embeddings EfficientNet-B5 (2048-мерные). Maximum Mean Discrepancy (MMD): 0.005415, permutation p-value = 0.0000. Classifier Two-Sample Test (C2ST, логистическая регрессия): accuracy = 0.9500, 95% CI: [0.9687, 0.9862].

Обе проверки указывают на статистически значимый дрейф распределений между обучающей и тестовой выборками.

4.7. Аномалии

Проверены базовые визуальные признаки: разрешение, aspect ratio, размытость (Laplacian variance), яркость, контраст и no-reference метрика BRISQUE. Extreme aspect ratio (<0.5 или >2.0): 754 изображений. Размытые изображения (Laplacian variance < 50): 490. Описательные статистики данных признаков представлены в Таблице №5.

Таблица №5 – Статистические характеристики визуальных признаков датасета

Признак	Mean	Std	Min	Max	Median
aspect_ratio	1.13	0.78	0.09	18.23	1.00
laplacian_blur	1585.48	2300.76	1.01	49506.17	892.06
brightness	111.03	31.67	16.67	243.08	113.91
contrast	51.01	13.16	14.67	94.42	50.93
brisque	23.50	16.91	-39.64	148.35	22.84

BRISQUE вычислен на изображениях, уменьшенных до 512 px по большей стороне, с помощью piq.brisque.

ЗАКЛЮЧЕНИЕ

Проведенное исследование качества данных выявило несколько свойств, которые могут существенно повлиять на интерпретацию результатов обучения и последующие эксперименты по робастности и приватности:

1. Высокая доля дубликатов (≈45% exact, ≈60% near) и сильная утечка train→test (≈62% тестовых образцов) делают оценку обобщающей способности завышенной. Baseline-метрики следует интерпретировать с осторожностью.

2. Обнаружен статистически значимый дрейф между train и test по MMD и C2ST, что дополнительно ограничивает обобщаемость выводов.

3. Доля подозрительных меток невелика (0.0146), но требует ручной проверки объектов с наименьшим значением label quality.

4. Баланс классов близок к равномерному; серьезных аномалий в разрешении и валидности файлов не выявлено.

5. Для повышения доверенности модели рекомендуется выполнить дедупликацию, устранить train-test leakage и повторно обучить baseline-модель на очищенных данных.

Ограничения.

Результаты относятся к текущему фиксированному разбиению данных и seed = 42. Доверительные интервалы для долей построены по интервалу Уилсона; для MMD приведена permutation p-value. BRISQUE вычислен на уменьшенных до 512 px изображениях;.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Northcutt C. G., Jiang L., Chuang I. L. Confident Learning: Estimating Uncertainty in Dataset Labels // Journal of Artificial Intelligence Research. – 2021. – Vol. 70. – P. 1373–1411.

2. Gretton A. et al. A Kernel Two-Sample Test // Journal of Machine Learning Research. – 2012. – Vol. 13. – P. 723–773.

3. Mittal A., Moorthy A. K., Bovik A. C. No-Reference Image Quality Assessment in the Spatial Domain // IEEE Transactions on Image Processing. – 2012. – Vol. 21, No. 12. – P. 4695–4708.

4. Mittal A., Soundararajan R., Bovik A. C. Making a Completely Blind Image Quality Analyzer // IEEE Signal Processing Letters. – 2013. – Vol. 20, No. 3. – P. 209–212.

5. Lee K. et al. Deduplicating Training Data Makes Language Models Better // Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (ACL 2022). – 2022. – P. 8424–8445.