МИНОБРНАУКИ РОССИИ
САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ
ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)
Кафедра ИС

ОТЧЁТ

по практической работе №2
по дисциплине: «Безопасность искусственного интеллекта»

Тема: Исследование устойчивости глубокой модели
к шуму и естественным искажениям

Бригада 5, гр. 1378
Виноградов А.С.
Угрюмов М.М.
Таланков В.Р.

Руководитель: Новикова Е.С.

Санкт-Петербург
2026

Содержание

1. Цель работы 4
2. Постановка задачи и фиксация параметров эксперимента 4
2.1. Аналитическая задача и контекст применения 4
2.2. Описание набора данных 4
2.3. Baseline-модель и основная метрика 4
2.4. Фиксация параметров эксперимента 4
3. Модель искажений 4
4. Методика оценки устойчивости 5
4.1. Robustness Curve 5
4.2. Интегральная метрика R-AUC 5
4.3. Доверительные интервалы 5
5. Результаты экспериментов 5
5.1. Сводная таблица по уровням искажений 5
Gaussian Noise 5
Gaussian Blur 6
Jpeg Compression 6
Brightness 6
Contrast 6
Salt And Pepper 6
5.2. Robustness Curves 6
5.3. Примеры искажённых изображений 7
5.4. Сравнение R-AUC 8
6. Заключение 9
Список использованных источников 10

1. Цель работы

Экспериментально оценить способность обученной baseline-модели сохранять качество классификации при естественных искажениях входных изображений (corruption robustness). Определить наиболее критичные типы и интенсивности искажений для выбранной предметной области.

2. Постановка задачи и фиксация параметров эксперимента

2.1. Аналитическая задача и контекст применения

Аналитическая задача — мультиклассовая классификация изображений листьев пшеницы по состоянию здоровья/заболеванию. Контекст применения: автоматическая диагностика заболеваний пшеницы по фотографиям листьев, например, в составе мобильного или веб-сервиса поддержки принятия решений агрономом.

2.2. Описание набора данных

Используется датасет C:\Users\andy7\stud\archive\data с Kaggle, сокращённый до 6 классов. Размер выборки: 6467 изображений; train=4922, valid=752, test=793. Модальность: цветные изображения RGB, нормализованные по статистикам ImageNet.

2.3. Baseline-модель и основная метрика

Архитектура: efficientnet_b5 с весами EfficientNet_B5_Weights.IMAGENET1K_V1. Классификационная голова: Dropout(0.2) + Linear(2048 -> 6). Backbone заморожен: True. Случайный seed: 42.

Основная метрика — Accuracy. Дополнительная — Macro-F1. На тестовой выборке baseline показывает Accuracy = 0.8449 [0.8180, 0.8684] (95% CI Уилсона), Macro-F1 = 0.8301 [0.8028, 0.8554] (bootstrap, B=2000).

2.4. Фиксация параметров эксперимента

Параметр	Значение
Число типов искажений	6
Число уровней интенсивности	4
Число независимых реализаций шума	7
Base seed для искажений	1000
Bootstrap-перевыборок	2000
Batch size	32
Устройство	cuda

3. Модель искажений

Для исследования corruption robustness выбраны шесть типов естественных искажений, характерных для фотографий, получаемых в полевых условиях: гауссов шум, гауссово

размытие, JPEG-сжатие, изменение яркости, изменение контраста и шум «соль и перец».

Тип искажения	Параметр	Уровни	Интенсивность
Gaussian Noise	Gaussian noise σ	0.01, 0.03, 0.05, 0.08	0.01, 0.03, 0.05, 0.08
Gaussian Blur	Gaussian blur radius	1.0, 2.0, 3.0, 5.0	1.0, 2.0, 3.0, 5.0
Jpeg Compression	JPEG quality	85, 65, 45, 25	15, 35, 55, 75
Brightness	Brightness factor	0.85, 0.7, 0.55, 0.4	0.15, 0.3, 0.45, 0.6
Contrast	Contrast factor	0.85, 0.7, 0.55, 0.4	0.15, 0.3, 0.45, 0.6
Salt And Pepper	Salt & pepper probability	0.01, 0.03, 0.05, 0.1	0.01, 0.03, 0.05, 0.1

Параметр интенсивность показывает монотонно возрастающую силу искажения и используется для корректного расчёта R-AUC методом трапеций. Для JPEG интенсивность = 100 − quality, для яркости/контраста = 1 − factor.

4. Методика оценки устойчивости

4.1. Robustness Curve

Для каждого типа искажения строится зависимость Accuracy от уровня интенсивности s. Точечная оценка усредняется по r независимым реализациям шума. Дополнительно рассчитываются абсолютное падение качества ΔM(s) = M(0) − M(s) и относительное сохранение R_rel(s) = M(s) / M(0).

4.2. Интегральная метрика R-AUC

Используется нормированная площадь под Robustness Curve: R-AUC = 1 / (s_max − s_min) · ∫ M(s) ds. На дискретной сетке интеграл вычисляется методом трапеций.

4.3. Доверительные интервалы

Для baseline Accuracy приведён 95%-й интервал Уилсона. Для Accuracy на искажённых данных и для R-AUC используется bootstrap по объектам тестовой выборки (B = 2000, percentile CI). Для разности ΔM(s) применяется парный bootstrap: на каждой итерации один и тот же набор индексов применяется к clean- и corrupted-предсказаниям.

5. Результаты экспериментов

5.1. Сводная таблица по уровням искажений

Gaussian Noise

Уровень	Accuracy	95% CI	Macro-F1	ΔAccuracy	95% CI Δ	R_rel	R-AUC
0.01	0.8287	[0.8036, 0.8523]	0.8081	0.0162	[0.0023, 0.0313]	0.9808	0.7670
0.03	0.7952	[0.7707, 0.8200]	0.7740	0.0497	[0.0274, 0.0742]	0.9412	0.7670
0.05	0.7467	[0.7200, 0.7736]	0.7287	0.0982	[0.0719, 0.1256]	0.8838	0.7670
0.08	0.6757	[0.6464, 0.7060]	0.6595	0.1692	[0.1414, 0.1989]	0.7998	0.7670

Gaussian Blur

Уровень	Accuracy	95% CI	Macro-F1	ΔAccuracy	95% CI Δ	R_rel	R-AUC
1.0	0.7932	[0.7642, 0.8197]	0.7779	0.0517	[0.0290, 0.0744]	0.9388	0.4868
2.0	0.4968	[0.4603, 0.5309]	0.5047	0.3480	[0.3115, 0.3859]	0.5881	0.4868
3.0	0.3253	[0.2938, 0.3569]	0.3236	0.5195	[0.4817, 0.5586]	0.3851	0.4868
5.0	0.2333	[0.2043, 0.2636]	0.2258	0.6116	[0.5725, 0.6482]	0.2761	0.4868

Jpeg Compression

Уровень	Accuracy	95% CI	Macro-F1	ΔAccuracy	95% CI Δ	R_rel	R-AUC
85	0.8348	[0.8083, 0.8600]	0.8158	0.0101	[-0.0076, 0.0277]	0.9881	0.8092
65	0.8096	[0.7831, 0.8361]	0.7880	0.0353	[0.0139, 0.0593]	0.9582	0.8092
45	0.7932	[0.7654, 0.8209]	0.7724	0.0517	[0.0290, 0.0757]	0.9388	0.8092
25	0.7692	[0.7402, 0.7995]	0.7502	0.0757	[0.0504, 0.0996]	0.9104	0.8092

Brightness

Уровень	Accuracy	95% CI	Macro-F1	ΔAccuracy	95% CI Δ	R_rel	R-AUC
0.85	0.8235	[0.7957, 0.8499]	0.8040	0.0214	[0.0038, 0.0391]	0.9746	0.8102
0.7	0.8197	[0.7932, 0.8462]	0.8026	0.0252	[0.0038, 0.0479]	0.9701	0.8102
0.55	0.7970	[0.7680, 0.8260]	0.7800	0.0479	[0.0252, 0.0731]	0.9433	0.8102
0.4	0.7566	[0.7264, 0.7881]	0.7329	0.0883	[0.0618, 0.1173]	0.8955	0.8102

Contrast

Уровень	Accuracy	95% CI	Macro-F1	ΔAccuracy	95% CI Δ	R_rel	R-AUC
0.85	0.8323	[0.8083, 0.8588]	0.8162	0.0126	[-0.0013, 0.0265]	0.9851	0.8184
0.7	0.8386	[0.8134, 0.8638]	0.8223	0.0063	[-0.0126, 0.0240]	0.9925	0.8184
0.55	0.8209	[0.7945, 0.8462]	0.7997	0.0240	[0.0038, 0.0467]	0.9716	0.8184
0.4	0.7188	[0.6873, 0.7503]	0.6922	0.1261	[0.0971, 0.1538]	0.8507	0.8184

Salt And Pepper

Уровень	Accuracy	95% CI	Macro-F1	ΔAccuracy	95% CI Δ	R_rel	R-AUC
0.01	0.7604	[0.7337, 0.7869]	0.7455	0.0845	[0.0596, 0.1095]	0.9000	0.6345
0.03	0.6619	[0.6312, 0.6928]	0.6468	0.1830	[0.1544, 0.2144]	0.7834	0.6345
0.05	0.6130	[0.5831, 0.6412]	0.5976	0.2319	[0.2016, 0.2636]	0.7256	0.6345
0.1	0.5250	[0.4965, 0.5561]	0.5008	0.3199	[0.2872, 0.3540]	0.6213	0.6345

5.2. Robustness Curves

На рисунке 1 приведены Robustness Curves для всех шести типов искажений с 95%-ми доверительными интервалами.

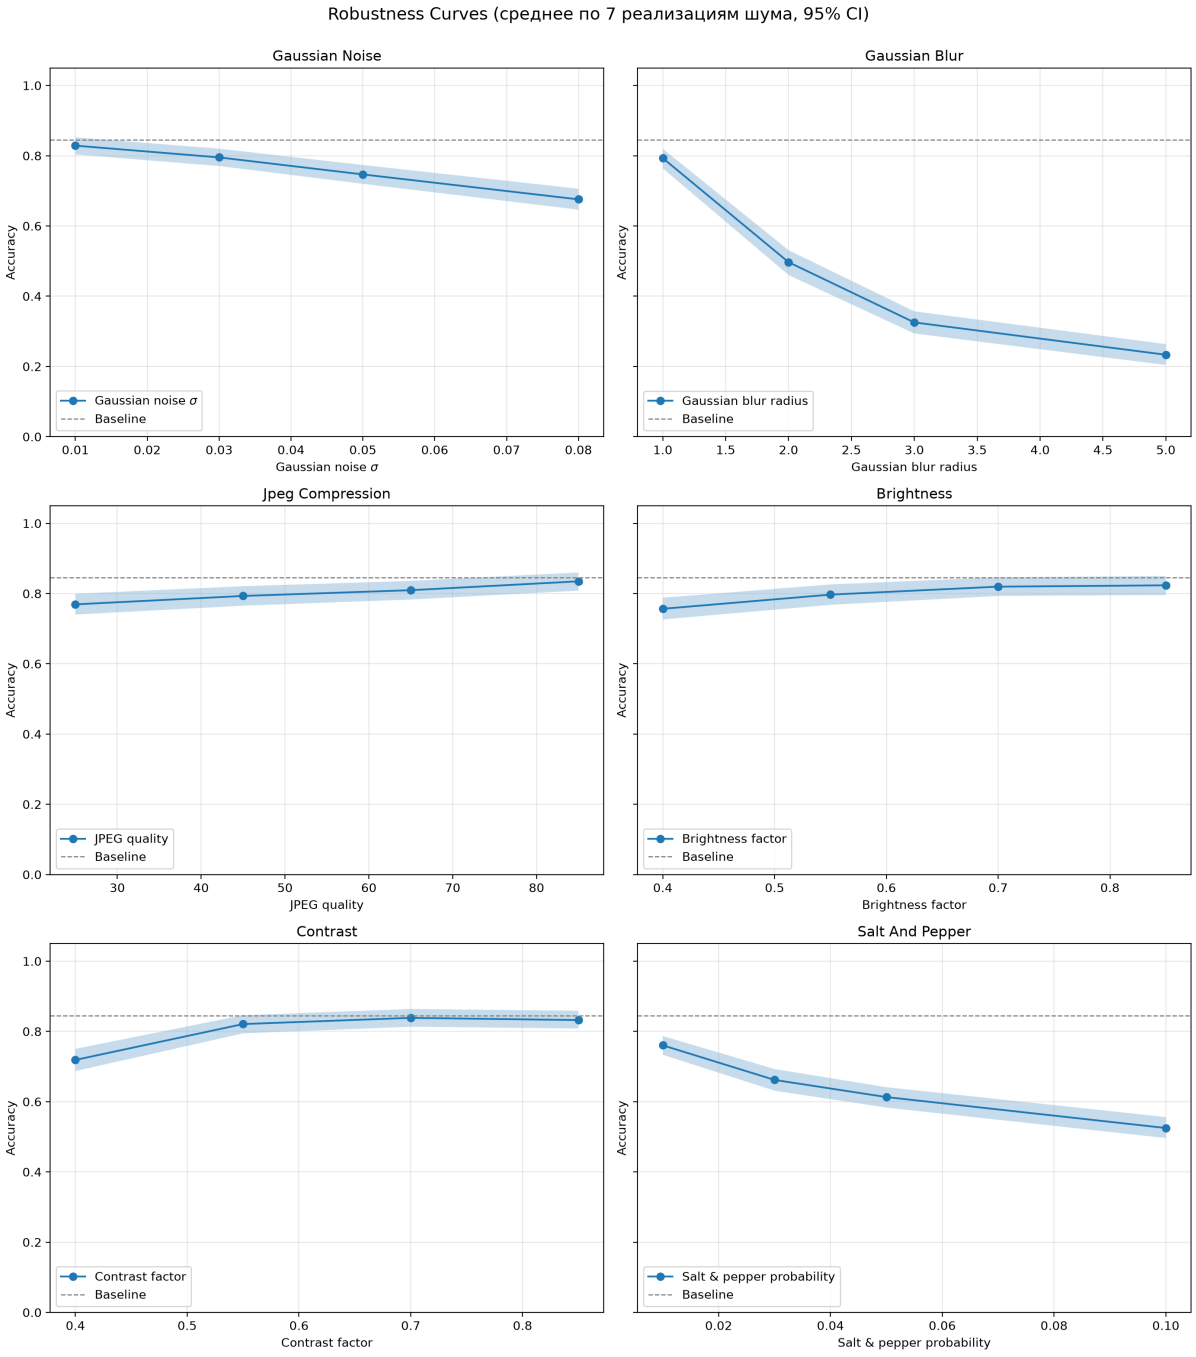

Рисунок 1 — Robustness Curves.

5.3. Примеры искажённых изображений

На рисунке 2 показаны примеры искажений одного и того же тестового изображения.

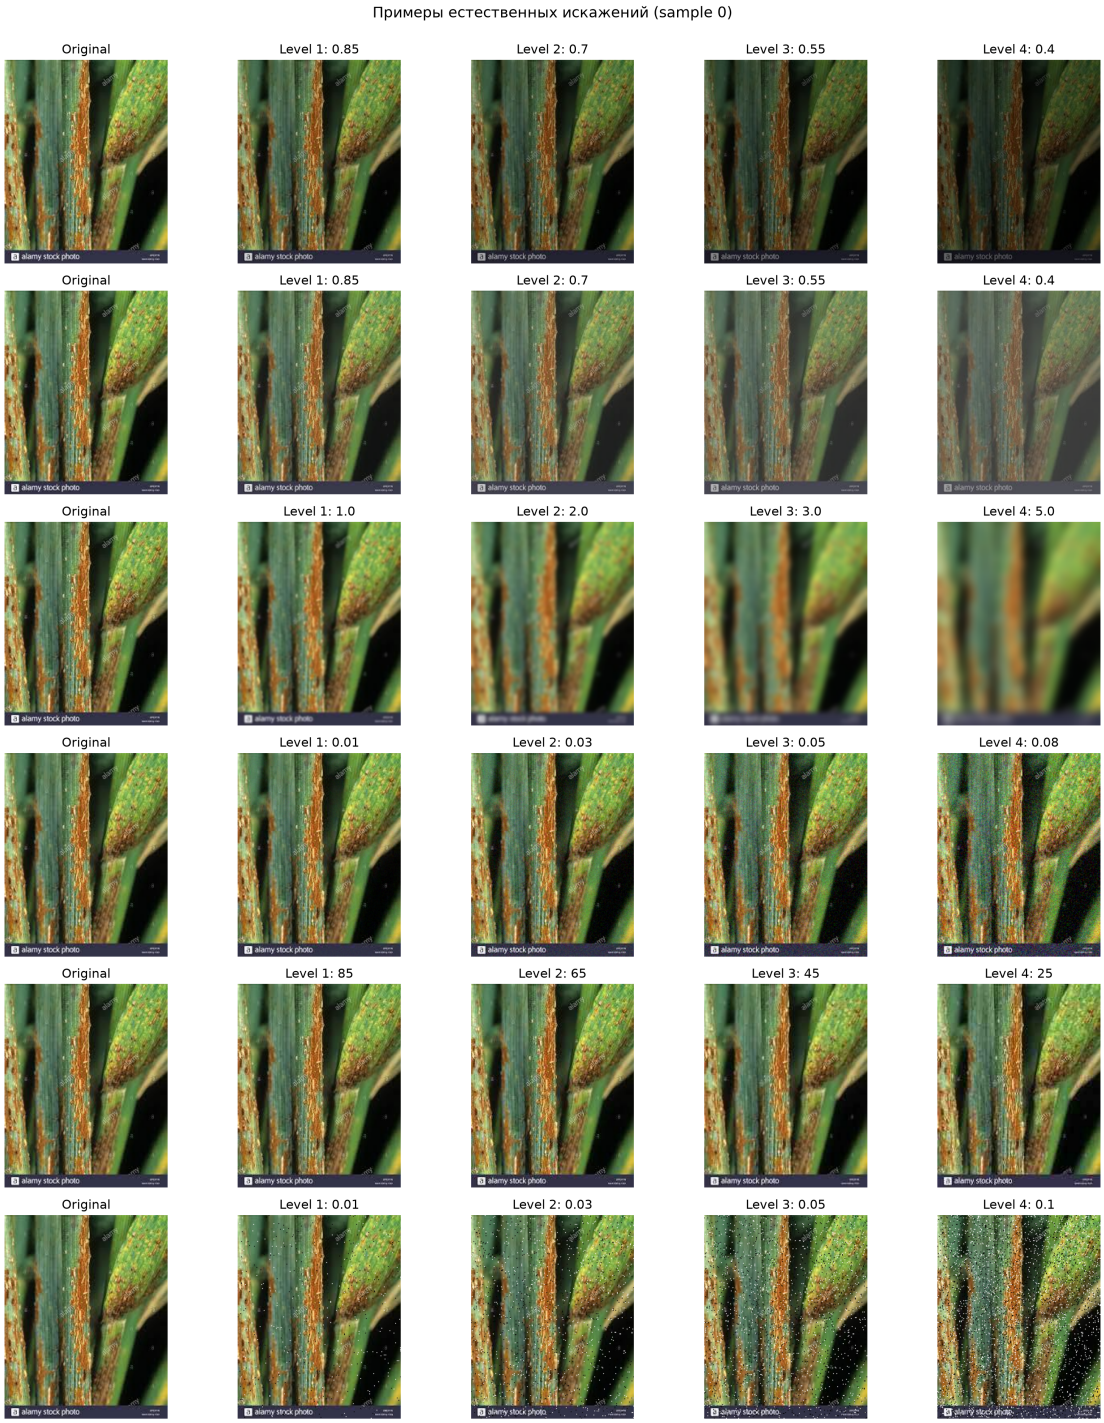

Рисунок 2 — Примеры естественных искажений.

5.4. Сравнение R-AUC

В таблице ниже приведены значения интегральной метрики R-AUC для каждого типа искажения с 95%-ми bootstrap-доверительными интервалами.

Тип искажения	R-AUC	95% CI
Gaussian Noise	0.7670	[0.7430, 0.7890]
Gaussian Blur	0.4868	[0.4648, 0.5082]
Jpeg Compression	0.8092	[0.7855, 0.8309]

Тип искажения	R-AUC	95% CI
Brightness	0.8102	[0.7877, 0.8307]
Contrast	0.8184	[0.7976, 0.8383]
Salt And Pepper	0.6345	[0.6095, 0.6594]

На рисунке 3 представлена столбчатая диаграмма R-AUC.

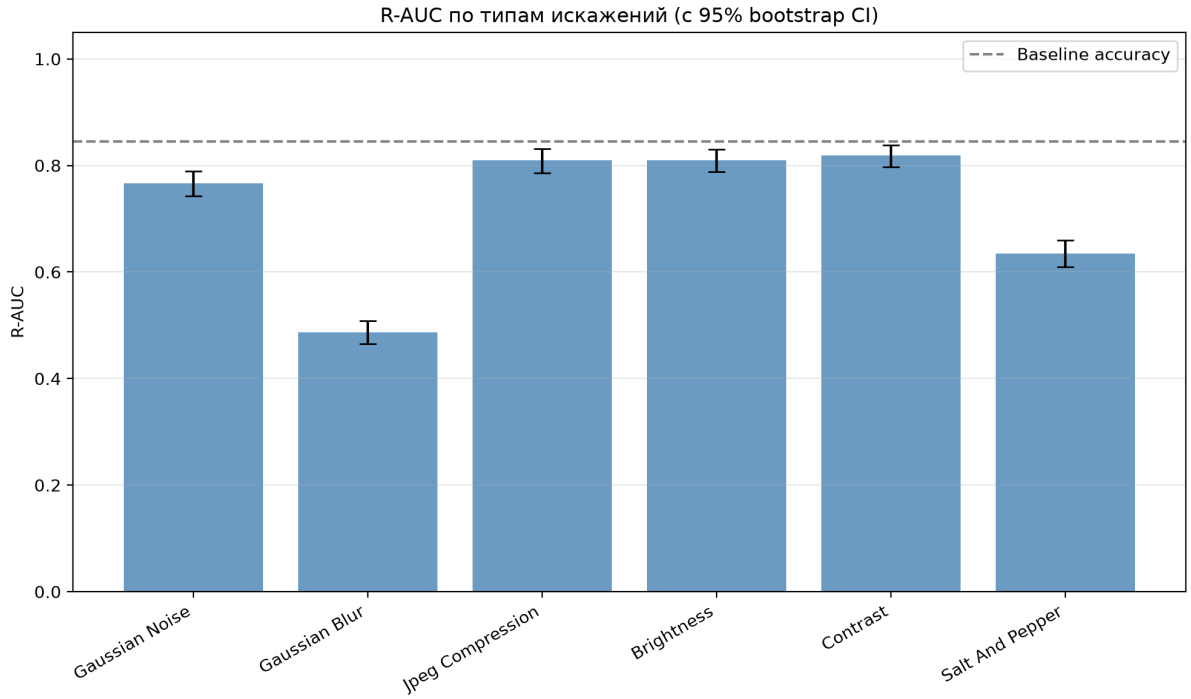

Рисунок 3 — R-AUC по типам искажений.

6. Заключение

Проведённые эксперименты показывают, что baseline-модель по-разному реагирует на различные естественные искажения. Наиболее критичным является гауссово размытие: уже при радиусе 2 px Accuracy падает ниже 0.50, а R-AUC составляет около 0.49. Значительное влияние оказывают также шум «соль и перец» и гауссов белый шум. JPEG-сжатие, изменение яркости и контраста в выбранных диапазонах приводят к более плавному снижению качества.

При интерпретации результатов необходимо учитывать выводы практической работы №1. В датасете выявлены высокая доля дубликатов (около 45% exact и 60% near-duplicate) и существенная утечка train→test (около 62% тестовых образцов). Кроме того, обнаружен статистически значимый дрейф распределений между обучающей и тестовой выборками (MMD p ≈ 0, C2ST accuracy ≈ 0.95). Эти факторы завышают абсолютные значения baseline-метрик и ограничивают обобщаемость выводов о robustness.

Тем не менее относительное сравнение типов искажений остаётся корректным в рамках зафиксированного протокола: наибольшую угрозу для надёжности полевой диагностики представляют дефокусировка и размытие, что должно учитываться при проектировании системы сбора изображений.

Список использованных источников

1. Hendrycks D., Dietterich T. Benchmarking Neural Network Robustness to Common Corruptions and Perturbations // ICLR. — 2019.
2. Efron B., Tibshirani R. J. An Introduction to the Bootstrap. — Chapman & Hall, 1993.
3. Northcutt C. G., Jiang L., Chuang I. L. Confident Learning: Estimating Uncertainty in Dataset Labels // Journal of Artificial Intelligence Research. — 2021. — Vol. 70. — P. 1373–1411.
4. Gretton A. et al. A Kernel Two-Sample Test // Journal of Machine Learning Research. — 2012. — Vol. 13. — P. 723–773.